



中国科学院大学
University of Chinese Academy of Sciences



基于深度卡尔曼滤波的时空降水预测

Deep Kalman Filtering for Spatiotemporal Precipitation Forecasting

董锐锋

Institute of Optics and Electronics, Chinese Academy of Sciences

2026 年 4 月 30 日





- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题




为什么降水预测这么难？

大气的本质：

- 极度复杂的非线性混沌系统
- 地表观测只是表象（Symptoms）
- 真正的驱动力是三维大气内部的物理状态

传统方法的困境：

- 端到端映射： $X_t \rightarrow X_{t+1}$
- 神经网络容易输出平均值
- 预测结果边缘模糊，丧失物理锐度






DKF 的破局之道：引入“隐状态”

核心思想：状态空间模型 (State Space Model)

假设存在一个无法直接测量的隐状态 Z_t ，它代表了大气的真实三维物理画像。



- **解耦：**将特征提取和物理演变分开
- **物理约束：**强制模型在隐空间中构建符合物理直觉的天气系统



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题



四大核心模块：大楼与脚手架

为了实现上述思路，我们将模型拆分为四个相互配合的子网络：

A. 物理引擎（承重墙）

1. 状态转移网络 (Prior)

- 输入: Z_{t-1}
- 输出: Z_t 分布
- 意义: 纯粹的动力学推演

2. 观测解码网络 (Emission)

- 输入: Z_t
- 输出: $\hat{X}_t$
- 意义: 将物理状态映射到地表观测

B. 校准工具（脚手架）


3. 特征编码器 (Encoder)

- 输入: 真实观测 X_t
- 输出: 降维特征向量
- 意义: 压缩地表网格数据

4. 后验推断网络 (Inference)

- 输入: $Z_{t-1} +$ 编码后的 X_t
- 输出: 校准后的 Z_t
- 意义: 利用真实观测修正预测

架构全景图





- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题



生成模型 p_θ (物理引擎)

$$p_\theta(Z_t|Z_{t-1}) = \mathcal{N}(\mu_{pt}, \Sigma_{pt}) \quad (\text{状态转移}) \quad (1)$$

$$p_\theta(X_t|Z_t) = \text{Decoder}(Z_t) \quad (\text{观测解码}) \quad (2)$$

识别网络 q_ϕ (校准工具)

$$q_\phi(Z_t|X_t, Z_{t-1}) = \mathcal{N}(\mu_{qt}, \Sigma_{qt}) \quad (3)$$

采用严格因果的 **q-RNN** 结构，从观测序列中提取纯净隐状态轨迹。



损失函数：变分下界 (ELBO)

优化目标为最大化 ELBO，即最小化以下两项之和：

$$\mathcal{L} = \underbrace{\|\hat{X}_t - X_t\|_2^2}_{\text{重构误差 (Reconstruction Loss)}} + \underbrace{D_{KL}(q_\phi(Z_t|X_t, Z_{t-1})\|p_\theta(Z_t|Z_{t-1}))}_{\text{KL 散度}} \quad (4)$$

1. 重构误差

- 计算 $\hat{X}_t$ 与 X_t 的 MSE
- 降水通道可加动态权重缓解数据不平衡

2. KL 散度

- 衡量后验与先验的差异
- 严禁采样，使用对角高斯闭式解析解



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题



训练阶段：双轨并行的校对

在训练时，我们拥有完整的天气记录，采用“教师-学生”机制：

1. 后验推断（教师/标准答案）：

- 利用脚手架（推断网络 q_ϕ ）
- 结合真实观测 X_t ，提取准确的隐状态轨迹

2. 先验预测（学生/做题）：

- 让状态转移网络 p_θ 自己根据 Z_{t-1} 推演 Z_t

3. 计算 KL 散度（纠正错误）：

- 强迫状态转移网络学习到真实的大气动力学规律

核心逻辑

推断网络 q_ϕ 提供监督信号，引导生成网络 p_θ 学习物理规律。



预测阶段：滚动预测 (Rolling Forecast)


预测阶段并非完全“盲飞”，而是**滚动推进**：当时间来到 $t+1$ 时，真实的 X_{t+1} 已经可获取，我们利用它来校准隐状态，再预测下一步。

单步流程（以 $t \rightarrow t+1$ 为例）：

1. 利用真实观测 X_t 和上一时刻 Z_{t-1}
2. 通过推断网络 q_ϕ 得到校准后的 Z_t
3. 通过先验网络 p_θ 预测 Z_{t+1}
4. 通过解码器得到 $\hat{X}_{t+1}$

下一步：

- 获取真实 X_{t+1}
- 用 X_{t+1} 和 Z_t 推断 Z_{t+1}
- 再预测 Z_{t+2} ，以此类推……



Contents



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题

数据集： WeatherBench (低分辨率 5.625° 或 2.8125°)

通道	变量	预处理
1	2 米温度	Z-score 标准化
2	10 米 U 向风速	Z-score 标准化
3	10 米 V 向风速	Z-score 标准化
4	总降水量	$\log(1 + x)$ 变换

降水预处理的重要性

降水数据极度稀疏且呈长尾分布，直接使用原始值会导致梯度爆炸或消失。 $\log(1 + x)$ 能稳定梯度反向传播。



空间结构保留

- 所有核心序列模块使用 **ConvLSTM** 或 **ConvGRU**
- 替代全连接 LSTM，保留二维空间拓扑

解码器设计

- 堆叠 **ConvTranspose2d** 进行空间上采样
- 温、风通道：线性激活
- 降水通道：Softplus/ReLU 确保非负

关键约束

- KL 散度必须解析计算，禁止蒙特卡洛采样
- 训练/预测模式通过 `self.training` 严格区分

Contents



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ **总结**
- ▶ 存在的问题

为什么选择 DKF?



DKF 的本质优势

DKF 并非简单堆砌数学公式，而是用深度学习重构了经典的大气系统动力学建模过程。

相比黑盒模型：

- 引入物理可解释的隐状态
- 解耦特征提取与动力学演变
- 预测结果保留物理锐度

相比传统卡尔曼滤波：

- 利用神经网络学习非线性转移/观测函数
- 无需手动设计复杂的状态转移矩阵
- 通过变分推断处理高维时空数据

目标： 构建一个既懂深度学习，又尊重大气物理规律的降水预测系统。

Contents



- ▶ 项目背景与动机
- ▶ DKF 核心架构
- ▶ 数学建模与网络设计
- ▶ 训练与预测：两种运行模式
- ▶ 数据与实现细节
- ▶ 总结
- ▶ 存在的问题



- 之前的两篇文献的数据集（HKO-7）雷达图像需要邮件联系作者获得
<https://github.com/sxjscience/HKO-7>
- 开源的数据集有 WeatherBench，但是其数据量非常大，完整的数据达到 TB 级别，因此若要使用，只能下载低分辨率的部分数据（如风速，气温和降水量），若要进行降水量预测，仅使用气温和风速是否有效？